Tablas Hash

...

Algoritmos y Estructuras de Datos
2024

UNRaf UNIVERSIDAD NACIONAL DE RAFAELA

Clase *dict*

- Se basa en el almacenamiento de pares de datos relacionados, denominados **clave** y **valor**.
- Cada clave es un elemento **único**, que tiene asociado un **valor** (los valores pueden repetirse).

Clase *dict*

- Para definir un objeto de la clase *dict* se utilizan llaves.
- Para acceder a valores dentro de un diccionario se utiliza una sintaxis similar a la de las **listas**.
- Las claves en un diccionario pueden ser **cualquier tipo de datos inmutable**, la única restricción es que cada clave debe ser un valor único.

```
monedas = {}
monedas["Argentina"] = "Peso"
monedas["Japon"] = "Yen"
print(monedas["Argentina"])
for m in monedas:
  print(monedas[m])
```

Operaciones de la clase *list*

M[k] = v	Asigna a la llave “k” el valor “v”.
M[k]	Devuelve el valor asociado a la llave “k”.
del M[k]	Elimina el par clave-valor.
len(M)	Devuelve el número de pares clave-valor.
k **in** M	Devuelve True si la llave “k” está presente en “M”.
M.keys()	Devuelve todas las claves dentro del diccionario.
M.values()	Devuelve todos los valores dentro del diccionario.
M.items()	Devuelve tuplas con todos los pares clave-valor.

Ventajas de utilizar diccionarios

- Los valores dentro de un diccionario pueden ser de cualquier tipo, incluidos otros datos abstractos (como diccionarios).
- Al igual que acceder a un elemento en una lista usando un índice, el acceso a un elemento usando su clave se da, en promedio, en **tiempo constante**.
- Esto es posible gracias al uso de las función ***hash***.

Función *hash*

- El objetivo de esta función es mapear cada clave con un entero.
- Si conceptualizamos a los pares clave-valor de un diccionario ubicados dentro de una lista, el objetivo de la **función *hash*** calculada sobre la **clave** es obtener **índice** para el **valor** correspondiente.
- Sin importar el tipo de dato, si logramos aplicar la función *hash* podremos acceder a un elemento en tiempo constante.

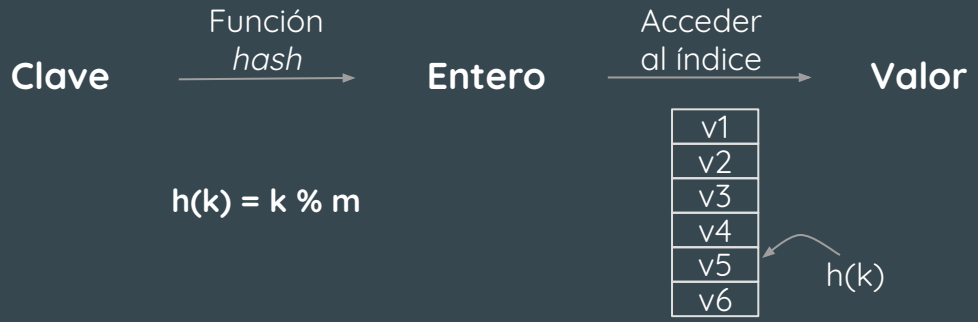

Función *hash*

- La selección de la función *hash* es un paso clave a la hora de diseñar una clase como *dict*.
- Es necesario que esta función pueda asignarle un entero a **cualquier clave que se quiera ingresar**.
- Si bien la función *hash* debe poder transformar cualquier valor en un entero (infinitas entradas), el resultado es el índice de una lista que posee un número limitado de elementos.

Colisiones

- Al limitar el tamaño de la lista de valores, se limita el número de índices que puede devolver la función *hash*.
- El mayor problema surge cuando la función devuelve el mismo resultado para 2 claves distintas.
- Cuando estas **colisiones** ocurren, es necesario aplicar una solución que permita seguir utilizando la misma función *hash* y almacenar los elementos conflictivos.

Colisiones

- Supongamos que tenemos los siguientes pares de datos:
  - 1, D
  - 3, F
  - 6, A
  - 7, Q
  - 14, Z
  - 25, C
  - 39, C

- Y usando el modulo (%) como función *hash* para armar una lista de 11 elementos se obtiene lo siguiente:
  - h(1) = 1
  - h(3) = **3**
  - h(6) = **6**
  - h(7) = 7
  - h(14) = **3**
  - h(25) = **3**
  - h(39) = **6**

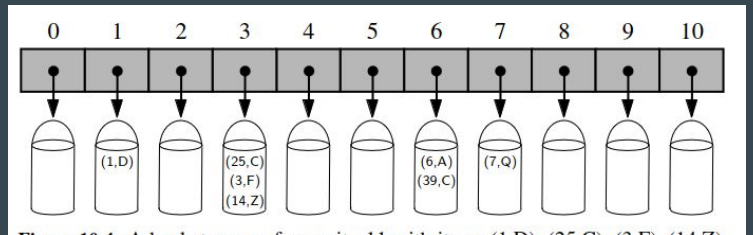

Figure 10.4: A bucket array of capacity 11 with items (1,D), (25,C), (3,F), (14,Z), (6,A), (39,C), and (7,Q), using a simple hash function.

Soluciones a las colisiones

- La solución más sencilla sería almacenar en el índice de la lista donde se produce la colisión una lista, con valores (k, v)
- Si hay más de una clave con el mismo resultado para la función *hash,* todas las posibilidades se pueden guardar en una lista de tuplas “clave-valor”.
- Esta estrategia se conoce como ***separate chaining*** o **encadenamiento separado.**

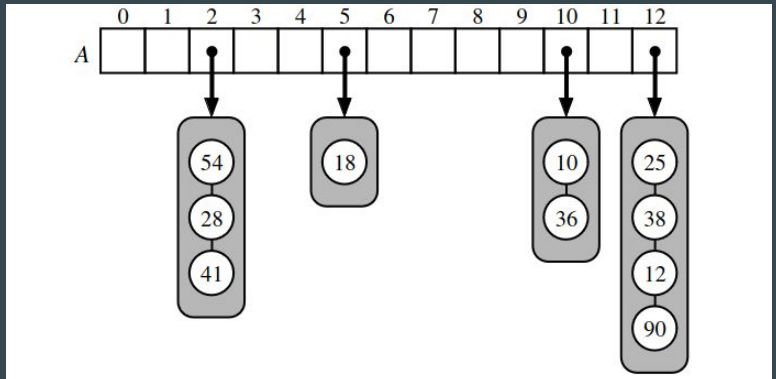

Figure 10.6: A hash table of size 13, storing 10 items with integer keys, with collisions resolved by separate chaining. The compression function is $h(k) = k \bmod 13$. For simplicity, we do not show the values associated with the keys.

Soluciones a las colisiones

- La mayor desventaja del encadenamiento es la utilización de espacio extra para las listas y de tiempo extra para su recorrido.
- Una serie de estrategias alternativas se denomina **direccionamiento abierto**.
- El ejemplo más simple es el **sondeo lineal**, donde se ocupa el siguiente elemento de la lista, si el correspondiente está ocupado

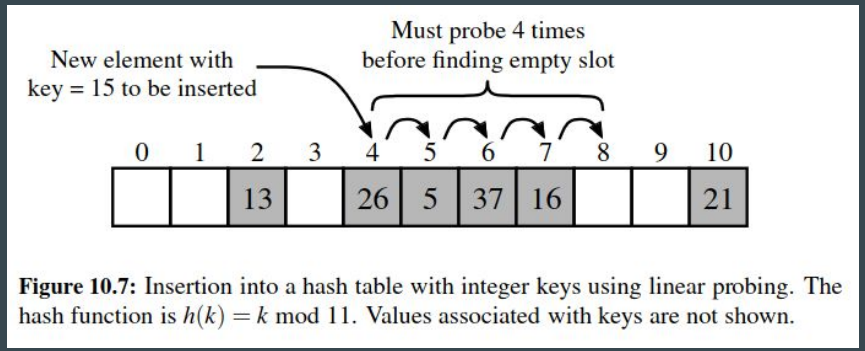

Figure 10.7: Insertion into a hash table with integer keys using linear probing. The hash function is $h(k) = k \bmod 11$. Values associated with keys are not shown.

Soluciones a las colisiones

- En el sondeo lineal, el espacio ocupado por un valor se puede calcular como ***h(k) + i***, siendo *i* = 0, 1, 2, 3, ...
- Otras alternativas para solucionar colisiones son
  - El **sondeo cuadrático**, similar al sondeo lineal, pero ***i*** toma los valores 1^2, 2^2, 3^2, 4^2.
  - El **doble hasheo**, donde se diseña una segunda función *hash* para asignar un nuevo índice dentro de la lista de claves-valores.
- Todas estas funciones intentan solucionar el problema de las colisiones, pero aumentan la complejidad de la búsqueda dentro de un diccionario.

Diccionarios en Python

- Python tiene incorporada la función *hash*, que permite calcular un valor entero a partir de un elemento inmutable.
- Esta función devuelve **números flotantes** (incluidos negativos), por lo que la clase *dict* incluye una segunda función, denominada de compresión, para transformar ese flotante en entero positivo.
- Para definir un diccionario, se utilizan las llaves (**{** y **}**), y los pares clave-valor se separan con dos puntos (**:**)

```
monedas = {"Argentina": "Peso",
           "Japon":     "Yen",
           "Italia":    "Euro" }
```

Ejemplo 1

- Diseñe un diccionario que almacene la cantidad de feriados nacionales en cada mes del 2024. Encuentre cuál es el mes con más feriados.

```
meses = {"Enero": 1,
         "Febrero": 2,
         "Marzo": 3,
         …
         "Diciembre": 2,
         }

mayor = 0
mes = ""
for m in meses:
  if meses[m] > mayor:
    mayor = meses[m]
    mes = m
```

Ejemplo 2

- El archivo *muestras.txt* contiene la siguiente información:

Muestra	Fecha	Edad	Provincia	Ciudad	Sexo
PAIS-E0810	2022-01-24	37	Santa Fe	Santa Fe	F
PAIS-E0811	2022-01-24		Santa Fe	Pilar	F
PAIS-E0812	2022-01-24	25	Santa Fe	Pilar	M
PAIS-E0813	2021-12-30	21	Misiones	Andresito	F
PAIS-E0815	2021-12-31	54	Misiones	Posadas	F

- Cargue todos los datos en un diccionario. Busque
  - Todas las muestras que sean de Misiones
  - Las muestras que vengan de pacientes con más de 40 años.

Ejemplo 2

```
muestras = {}
with open ("muestras.txt") as ifh:
  ifh.readline()
  for l in ifh:
    l = l.rstrip()
    linea = l.split("\t")
    muestras[linea[0]] = {}
    muestras[linea[0]]["Fecha"] = linea[1]
    muestras[linea[0]]["Edad"] = int(linea[2])
    muestras[linea[0]]["Provincia"] = linea[3]
    muestras[linea[0]]["Ciudad"] = linea[4]
    muestras[linea[0]]["Sexo"] = linea[5]

for m in muestras:
  if muestras[m]["Provincia"] == "Misiones":
    print(m)

for m in muestras:
  if muestras[m]["Edad"] != "" and int(muestras[m]["Edad"]) > 40:
    print(m)
```

Bibliografía

- Goodrich, M. T., Tamassia, R., & Goldwasser, M. H. (2013). Data structures and algorithms in Python. Capítulo 10.
- Cormen, T. H., Leiserson, C. E., Rivest, R. L., & Stein, C. (2022). Introduction to algorithms. MIT press. Capítulo 11.